



**Ministério da Educação**  
**Universidade Federal do Piauí – UFPI**  
**Campus Senador Helvídio Nunes de Barros – Picos**  
**Bacharelado Em Sistemas de Informação**  
**Tópicos Em Visão Computacional**  
**Prof.Alcilene Dalila De Sousa**



*João dos Santos Neto*  
*Marcos Vinicius Batista Sampaio*  
*Alisson Rodrigo Carneiro da Silva*  
*Jorge Luis Ferreira Luz*

**Relatório**

## **I.O embasamento teórico do método de agrupamento escolhido para segmentação (etapa III da questão 1).**

### **Como funciona:**

O Método de Marr-Hildreth, também conhecido como Laplaciano do Gaussiano (LoG), é um método de detecção de bordas que combina duas operações importantes: a suavização (filtragem) da imagem pelo operador Gaussiano e a detecção de mudanças abruptas na intensidade usando o operador Laplaciano. Aqui está uma explicação de como o método funciona e algumas de suas vantagens:

### **Suavização com Filtro Gaussiano:**

O primeiro passo envolve a suavização da imagem original usando um filtro Gaussiano. Isso é feito para reduzir o ruído na imagem e destacar as mudanças de intensidade mais significativas, que correspondem às bordas.

### **Detecção de Bordas com Laplaciano:**

Após a suavização, é aplicado o operador Laplaciano para destacar as mudanças de intensidade na imagem. O Laplaciano é usado para encontrar a segunda derivada da imagem e é sensível a mudanças bruscas de intensidade, como as que ocorrem em bordas.

### **Zerocrossing para Localizar Bordas:**


A detecção de bordas é frequentemente realizada procurando por cruzamentos de zero no sinal do Laplaciano. Isso significa que a borda é identificada onde a transição de intensidade ocorre, resultando em uma mudança de sinal no Laplaciano.

### **Conversão de Sinal para Imagem Binária:**

O resultado final é frequentemente convertido para uma imagem binária, onde as bordas são representadas por pixels brancos e o resto da imagem é preto.


## **II.As saídas das três metodologias de segmentação.**

## K-means




## Binarização local e global:


Local



Global



**Marr Hildreth**



**Algoritmo de agrupamento (DBSCAN) e detector de bordar (Sobel):**



## Foreground e Background



### III. O detalhamento do método de escolha do fore/background.

Este método utiliza técnicas de processamento de imagem, como conversão para escala de cinza, binarização e operações bitwise, a fim de destacar automaticamente áreas de interesse.

#### Conversão para Escala de Cinza:

A primeira etapa do método consiste na conversão da imagem de entrada para escala de cinza. Essa transformação simplifica a análise da intensidade de brilho, facilitando as etapas subsequentes do processo.

A imagem colorida original é convertida para escala de cinza. Isso é feito utilizando a função `cv2.cvtColor(image, cv2.COLOR_BGR2GRAY)`.

#### Binarização da Imagem:

A imagem em escala de cinza é binarizada usando o método de Otsu. Esta abordagem automática determina um valor de limiar que minimiza a variabilidade intra-classe na imagem binarizada. A função `cv2.threshold` com a flag `cv2.THRESH_BINARY + cv2.THRESH_OTSU` é empregada para alcançar esse resultado.

**Geração do Foreground e Background:**

Utilizando a imagem binarizada como máscara, são gerados o foreground e o background. O foreground é obtido através da operação `cv2.bitwise_and(image, image, mask=binary)`, que preserva apenas as regiões da imagem original onde a máscara (binarizada) é não zero, resultando no primeiro plano destacado.

O background é gerado pela operação `cv2.bitwise_and(image, image, mask=cv2.bitwise_not(binary))`. Neste caso, a máscara é invertida utilizando `cv2.bitwise_not`, e as regiões onde a máscara invertida é não zero são mantidas, constituindo o segundo plano.

O método proposto oferece uma abordagem eficaz para a seleção automática de foreground e background em imagens. As técnicas empregadas demonstram a capacidade de identificar automaticamente áreas de interesse com base nas características intrínsecas da imagem. Este método pode ser aplicado em diversas áreas, incluindo processamento de imagens e visão computacional, onde a segmentação de objetos é essencial.

**Binarização usando Otsu:**

O método de Otsu é empregado para realizar a binarização da imagem em escala de cinza. Este método automaticamente determina um valor de limiar que otimiza a separação entre os pixels de primeiro plano e segundo plano. A função `cv2.threshold` é utilizada para essa binarização: `cv2.threshold(gray, 0, 255, cv2.THRESH_BINARY + cv2.THRESH_OTSU)`.

**Obtenção de Regiões de Primeiro Plano e Segundo Plano:**

A máscara binária resultante é utilizada para aplicar a operação lógica AND na imagem original. O foreground contém as regiões de primeiro plano, onde a máscara é branca.

O background contém as regiões de segundo plano, onde a máscara é preta. Este método assume que a diferença de intensidade de pixel entre primeiro plano e segundo plano é suficientemente significativa para permitir uma segmentação eficaz.

Variações na iluminação e presença de ruído podem impactar os resultados.

#### **IV. Os resultados obtidos com as métricas de avaliação:**

A segmentação foi realizada utilizando a binarização de Otsu. Esta é uma técnica simples de segmentação baseada em limiar, onde o limiar é automaticamente escolhido usando o método de Otsu para otimizar a separação entre os pixels de primeiro e segundo plano.

**Dice Coefficient:**

Foi calculado usando a fórmula:  $2 \times \text{intersection} / (\text{sum of pixels in mask\_reference} + \text{sum of pixels in segmented\_mask})$

Essa métrica mede a sobreposição entre a máscara segmentada e a máscara de referência.

**Jaccard Index (IoU):**

Foi calculado usando a fórmula:  $\text{intersection} / \text{union}$



Esta métrica também mede a sobreposição entre a máscara segmentada e a máscara de referência.

**Métricas Agregadas:**

Dice Coefficient Agregado: 0.5923242798771723

Jaccard Index Agregado (IoU): 0.42078176913180587

**V. Uma conclusão explicando qual técnica foi melhor e o motivo**

Ao analisar as técnicas de segmentação aplicadas às imagens ultrassom, torna-se evidente que a abordagem focada no foreground sobressai como a mais eficaz. Entre as diversas técnicas avaliadas, o destaque recai sobre a estratégia que prioriza a segmentação do primeiro plano da imagem. Essa conclusão é fundamentada em várias observações significativas:

**Relevância Clínica:**

Em imagens médicas, como as de ultrassom, o foreground muitas vezes contém informações críticas, como estruturas anatômicas e regiões de interesse. Portanto, direcionar esforços para destacar o primeiro plano é crucial para a interpretação clínica.

**Ênfase na Detecção de Detalhes Importantes:**

A ênfase na segmentação do foreground proporciona uma representação mais nítida de detalhes e características relevantes nas imagens. Essa abordagem ressalta aspectos clínicos importantes, facilitando a identificação de patologias e a tomada de decisões médicas.

**Redução de Ruídos e Distratores:**

Ao concentrar-se no primeiro plano, há uma natural redução de ruídos e elementos indesejados do background, permitindo uma visualização mais limpa e precisa das estruturas médicas de interesse.

**Facilidade na Interpretação Visual:**

A segmentação eficaz do foreground contribui para uma interpretação visual mais intuitiva e rápida por parte dos profissionais de saúde. Isso é essencial em ambientes clínicos onde o tempo é muitas vezes um fator crítico.

Em conclusão, a escolha de priorizar a segmentação do foreground revela-se como uma estratégia altamente eficiente e relevante em contextos médicos, especialmente em imagens de ultrassom. Essa abordagem destaca-se não apenas por sua capacidade de destacar detalhes cruciais, mas também por sua contribuição para uma interpretação mais precisa e informada por parte dos profissionais da saúde.

